

Departamento de Informática

Aprendizagem Computacional 2023/2024

Mestrado em Engenharia Biomédica

Assignment 2

Prediction and detection of epileptic seizures

Grupo 3, Prática Laboratorial 1

Duarte Ferreira (2020235393)

Cristiana Azevedo (2020221121)

20.novembro.2023

1. Introdução

A epilepsia é um distúrbio neurológico crônico caracterizado por convulsões recorrentes. As convulsões resultam de uma alteração da atividade elétrica do cérebro e podem resultar de um trauma, de uma tendência familiar ou não terem causa identificável. Essa atividade ou descarga tem um início imprevisível e é, em geral, de curta duração (segundos a minutos, raramente ultrapassando os 15 minutos) mantendo-se o funcionamento cerebral normal entre crises. Estas têm tendência a repetir-se ao longo do tempo, sendo a frequência variável entre doentes. A epilepsia afeta diversas funções mentais e físicas e é uma condição muito comum, ocorrendo em cerca de 65 milhões de pessoas em todo o mundo. Nos Estados Unidos, é a quarta doença neurológica mais habitual, ultrapassada apenas pela enxaqueca, pelo acidente vascular cerebral e pela doença de Alzheimer. Em Portugal, estima-se que atinja quatro a sete mil habitantes. Contudo, o número de indivíduos que, não sendo epiléticos, pode ter uma crise convulsiva durante a vida é de cerca de uma em cada 20.

O principal objetivo deste trabalho consiste em desenvolver redes neuronais, sustentadas em mecanismos de *shallow* e *deep learning* capazes de prever e detetar possíveis ataques epiléticos por meio da análise de características extraídas de EEG de dois pacientes distintos, os quais compõem a nossa base de dados. Para atingir esse propósito, foram implementadas redes neuronais com três saídas, uma para cada classe de estado cerebral. A primeira classe, denominada Interictal, representa o estado cerebral normal, sendo representada na saída da rede neural como [1 0 0]. A segunda classe, Preictal, indica que uma crise está iminente, sendo expressa na saída da rede como [0 1 0]. A terceira classe, Ictal, indica que uma crise está em curso, e sua representação na saída da rede é [0 0 1]. Esse modelo tridimensional permitirá uma classificação eficiente dos diferentes estados cerebrais, contribuindo para a deteção e previsão de crises epiléticas com base nas características extraídas do EEG.

2. Dataset

Com o intuito de antecipar e identificar crises epiléticas, empregou-se o sinal de EEG de dois pacientes diferentes: o Paciente 44202 e o Paciente 63502. A partir de cada EEG, foram extraídas 29 características, as quais refletem o espectro de frequência do canal de EEG, abrangendo a faixa de 0,5 a 512 Hz.

Tabela 1. Detalhes dos pacientes da base de dados

ID	Sexo	Idade	Tempo da doença (anos)	Tempo de Gravação de EEG (h)	Nº de ataques
44202	Masculino	21	5	170,6	199
63502	Feminino	63	30	118,9	156

3. Pré-Processamento

Antes de realizar o treino e o teste de redes neuronais, foi necessário realizar um pré-processamento nos dados extraídos dos EEGs. O vetor *target* (Trg) original continha apenas duas classes: ictal (1) e não-ictal (0) que identifica a ocorrência das crises epiléticas. Para atender aos objetivos delineados para este trabalho, recorreu-se a uma transformação convertendo essas duas classes em três classes distintas:

- **Inter-Ictal** (classe 1) – Representa o estado normal do cérebro.
- **Pré-Ictal** (classe 2) – Representa o período antecedente à crise epilética. Inclui 300 pontos (5 minutos) antes do primeiro ponto ictal de cada crise.
- **Ictal** (classe 3) – Representa o período da crise epilética. Ainda abrange 60 pontos (1 minuto) após o último ponto ictal de cada crise.

Após estes ajustes, foi construída uma matriz alvo T , em que cada classe foi substituída por um vetor coluna contendo apenas uns e zeros. Ou seja, a fase Inter-Ictal ficou como $[1\ 0\ 0]^T$, a fase Pré-Ictal como $[0\ 1\ 0]^T$ e a fase Ictal como $[0\ 0\ 1]^T$. O conjunto de dados para cada paciente foi posteriormente dividido em conjuntos de treino e teste, seguindo uma razão de 90:10 para cada conjunto, garantindo assim que cada conjunto continha uma proporção apropriada de crises epiléticas. No caso das redes *Shallow Neural Networks* (SNN), uma parte do conjunto de treino foi utilizada para validação (20%).

Na verdade, o número de pontos da classe Inter-Ictal é bastante superior ao das restantes classes, correspondendo a cerca de 90% do registo do EEG, visto que se trata de uma fase do funcionamento normal do cérebro. Tendo em conta este desequilíbrio substancial do número de instantes da classe Inter-Ictal, foi realizada uma equalização de classes nos conjuntos de treino e validação para cada paciente. Ou seja, foi reduzido o número de pontos Inter-Ictal de forma a igualar a soma de pontos das outras duas classes, Pré-Ictal e Ictal.

No caso das *deep networks*, foram realizadas etapas adicionais e independentes de pré-processamento. Para as *Long Short-Term Memory Networks* (LSTM), o conjunto de dados foi convertido numa matriz de células, em que cada célula continha um vetor coluna com 29 *features* para cada instante. Simultaneamente, a matriz alvo foi transformada num vetor categórico com rótulos 1, 2 e 3 correspondendo a diferentes classes.

As *Convolutional Neural Networks* (CNN) exigiram a conversão do conjunto de dados em imagens 2D por meio de janelas quadradas que representavam matrizes de 29 *features* por 29 instantes da mesma classe. Posteriormente, uma matriz 4D foi construída para os conjuntos de treino, validação e teste. Nessa matriz, as dimensões de cada imagem eram $29 \times 29 \times 1 \times \text{NúmeroDeImagens}$. Semelhante às redes LSTM, o vetor alvo correspondia a um vetor categórico, com cada linha indicando a classe da respetiva imagem (1, 2 e 3).

3.1 Redução de Features

O número de *features* para cada paciente foi reduzido com auxílio de *autoencoders*. Consiste num tipo de rede não supervisionado constituído por três componentes principais: *encoder*, responsável por aprender a reduzir as dimensões do input numa representação codificada, o *bottleneck*, que armazena os dados na sua forma comprimida, e o *decoder*, com a capacidade de reconstruir os dados de maneira que estes sejam semelhantes aos dados iniciais.

Os *autoencoders* foram utilizados para reduzir as 29 *features* em 15, 10 e 5 *features*. Este procedimento permite então reduzir o peso computacional associado ao treino das várias opções de redes disponíveis, através da redução da dimensão dos inputs.

3.2 Clustering

O clustering é uma técnica que visa organizar os dados em grupos com base nas suas semelhanças e diferenças, formando grupos homogêneos e bem separados entre si. No contexto deste trabalho, os conjuntos de dados que foram reduzidos a apenas três *features* possibilita a visualização da distribuição dos dados num gráfico 3D. Utilizando métodos de agrupamento, os dados foram organizados em três *clusters* representando as classes interictal, pré-ictal e ictal.

O algoritmo de clustering escolhido para este estudo foi o *K-means*, um método geralmente utilizado que inicia com uma partição aleatória dos dados e atribui novos dados aos clusters com base na distância euclidiana entre o padrão e o *cluster*. Assim, ao utilizarmos esta abordagem pretende-se realizar uma pré-análise visual das relações entre as diferentes classes e *clusters*, contribuindo para a compreensão da estrutura subjacente dos dados.

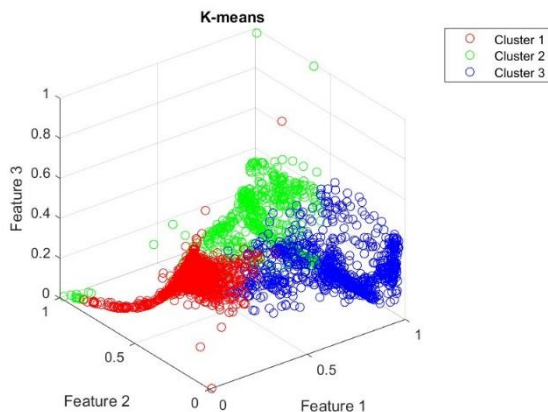


Figura 1. Clustering com k-means para o paciente 44202

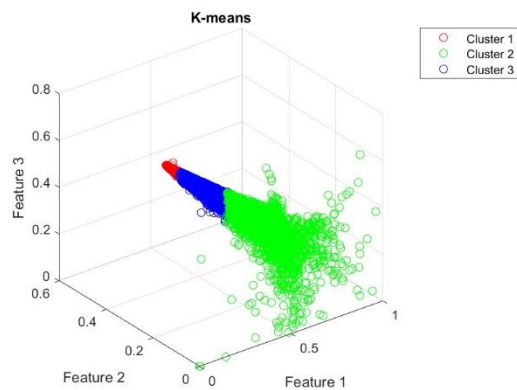


Figura 2. Clustering com k-means para o paciente 63502

No entanto, analisando os gráficos anteriores, torna-se evidente a ausência de uma divisão clara entre as classes interictal, pré-ictal e ictal. Neste sentido, não é possível identificar padrões distintos para nenhum dos pacientes. Diante disso, concluímos que o algoritmo de clustering *K-means* não é capaz de fornecer informações relevantes sobre o conjunto de dados em questão.

4. Arquitetura da Rede Neuronal

4.1 Shallow Neural Networks

Relativamente às *Shallow Neural Networks* (SNN), procurou-se construir e treinar dois tipos diferentes de redes: *Feed Forward Network* (FFN), uma abordagem estática que não possui atrasos, e *Layer Recurrent Network* (LRN), uma abordagem dinâmica que incorpora *feedback* entre a saída e a entrada de cada camada. Dado que o cérebro é dinâmico e possui memória, a introdução de atrasos nas redes pode ser uma estratégia vantajosa para resolver o problema proposto, utilizando a função *layercnet*.

Para ambos os casos de SNN, e com o intuito de identificar as redes mais eficientes na previsão e deteção de ataques epiléticos, foram desenvolvidas várias redes neuronais variando nos seguintes parâmetros:

- Número de camadas – 1 a 3;
- Neurónios – 1 a 5;
- Funções de ativação - *purelin*, *logsig* e *tansig*;
- Funções de treino - *traingd*, *traingda*, *traingdm*, *trainlm*, *trainscg*;
- *Delays* – 1 a *n* com *n* entre 1 e 5;
- *Optimization* - Parallel, GPU, ...
- *Training Style* - *incremental learning*, *batch learning*.

Nesta rede, foi implementado um vetor de pesos para balanceamento, conforme mencionado anteriormente, utilizando a *Deep Learning Toolbox* do MATLAB.

Mesmo com o balanceamento das classes realizado no pré-processamento, o número de instantes de cada classe não era o mesmo, por isso, também foi utilizado um vetor de pesos para treinar as redes neuronais. Este vetor foi projetado de forma que o peso de cada classe fosse inversamente proporcional ao número de instantes da respetiva classe.

4.2 Deep Neural Networks

No caso das *Deep Neural Networks* (DNN), foram consideradas dois tipos de redes: as *Convolutional Neural Networks* (CNN) e as *Long Short-Term Memory Networks* (LSTM).

As redes LSTM são um tipo de rede neuronal recorrente que possuem memória a curto e longo prazo, podendo serem separadas em dois tipos: as unidirecionais, que apenas preservam e analisam informações do passado, e as bidirecionais, que têm uma entrada do passado para o futuro e uma entrada do futuro para o passado, preservando informações do passado e do futuro.

Neste trabalho foram abordadas redes LSTM de simples de classificação. As componentes principais são uma *sequence input layer* e uma camada LSTM. Uma *sequence input layer* insere dados de sequência ou séries temporais na rede. Uma camada LSTM aprende a longo prazo as dependências entre os intervalos tempo de dados sequenciados. Para prever *class labels*, a rede ainda possui uma camada totalmente conectada, uma camada *softmax* e uma camada de saída de classificação. Com o objetivo de tornar as redes LSTM mais profundas, foi empregada apenas uma camada interna, uma *LSTM layer*, com uma quantidade variável de *hidden units* entre 20 e 4000, e uma saída configurada como "last", onde foi atribuída uma classe para cada instante temporal.

No contexto das redes CNN, estas são construídas primeiramente com uma camada de input que aceita imagens com um tamanho de entrada definido como $(29 \times 29 \times 1)$. Estas redes foram treinadas com 1, 2, ou 3 camadas de *convolutional layers*. Para além de ser necessário definir o número de camadas, também foi necessário definir o tamanho, o número e o *stride* dos filtros utilizados na mesma. A cada *convolutional layer*, estavam sempre associadas uma *batchNormalizationLayer*, uma *reluLayer* e uma *poolingLayer*. A *batchNormalizationLayer* tem o intuito de normalizar os inputs, tornando o treino mais rápido, a *reluLayer* consiste numa função de ativação em que os valores são mantidos os mesmo caso sejam positivos ou então são transfrmados em zero se forem negativos. Já quanto ao *poolingLayer*, este pode ser do tipo *max pooling layer* ou *average pooling layer* em que foi necessário definir o tamanho e o *stride* dos *poolings*.

Na verdade, ambas as redes foram otimizadas com os *solvers adam*, *rmsprop* e *sgdm*, cada um com diferentes valores de *epochs*.

Em suma, para estudar a eficiência das redes DNN na previsão e deteção de ataques epiléticos, foram desenvolvidas diversas redes neuronais variando nos seguintes parâmetros:

LSTM:

- *Hidden units* - entre 20 e 4000;
- *Epochs* – entre 10 e 200;
- *Solver* - *adam*, *rmsprop* e *sgdm*;
- *Layer* – 1 ou 2.

CNN:

- Camadas Convulcionais - 1, 2 ou 3;
- Número de filtros – entre 1 e 5;
- Tamanho dos filtros - entre 1 e 5;
- *ConvStride* – entre 1 e 4;
- *Pooling* - *max* ou *average pooling layer*;
- Tamanho *Pooling* – entre 1 e 4;
- *Pooling Stride* – entre 1 e 4;
- *Epochs* – entre 50 e 2000;
- *Solver* - *adam*, *rmsprop* e *sgdm*;

5. Pós-Processamento

O desempenho das redes neuronais desenvolvidas foi medido pela Sensibilidade (SE) que determina quantas convulsões verdadeiras foram previstas ou detetadas) e pela Especificidade (SP) que calcula quantas convulsões falsas foram previstas ou detetadas. Estas duas medidas foram determinadas por meio da matriz de confusão e por dois métodos distintos: o *Point by Point* e o *Seizure by Seizure*. É importante referir que para utilização clínica, são necessárias uma Sensibilidade e uma Especificidade elevadas.

$$\text{Sensibilidade} \rightarrow SE(\%) = \frac{\text{True Positives}}{\text{True Positives} + \text{False Negatives}} \times 100$$

$$\text{Especificidade} \rightarrow SP(\%) = \frac{\text{True Negatives}}{\text{True Negatives} + \text{False Positives}} \times 100$$

No método *Point by Point*, cada ponto temporal é atribuído a uma das classes, e os erros e a performance são calculados ponto a ponto. Para as redes CNN, compara-se o *output* do classificador para cada imagem com o valor do *target*. Já para as redes LSTM e SNN, compara-se o *output* do classificador com o valor do *target* no mesmo instante temporal. A matriz de confusão é gerada, permitindo calcular os casos verdadeiros positivos (TP), falsos negativos (FN), verdadeiros negativos (TN) e falsos positivos (FP) para as classes Ictal e Pré-Ictal, representando previsão e detecção, respetivamente.

Dado que no EEG não existem instantes isolados pertencentes a uma única classe e o sinal é representado por um espectro de frequências com 29 *features*, o método *Point by Point* pode não ser o mais adequado devido ao ruído presente. Surge, então, o método *Seizure by Seizure*, que avalia os dados de forma mais abrangente.

Neste método, para cada instante, considerou-se blocos de 10 pontos consecutivos e, se pelo menos 5 deles correspondessem a uma classe específica, então, esse instante seria classificado como a classe predominante. Em teoria, isso deveria ajudar a reduzir os problemas associados ao primeiro método. Assim como no método *Point by Point*, os valores de TP, FN, TN, FP foram calculados por meio da matriz de confusão, mas neste caso foi posteriormente determinado a *accuracy* da rede, dividindo o número de crises epiléticas detetadas corretamente, pelo número de crises epiléticas que ocorreram verdadeiramente.

6. Interface

Com o objetivo de simplificar a interação, desenvolvemos uma GUI (Interface Gráfica do Utilizador) acessível através da aplicação `interface.mlapp`, assumindo que o diretório de trabalho do MATLAB é a pasta *Códigos* em *ML2023EpilepPLIG3*.

A primeira aba da interface fornece informações gerais sobre o projeto, incluindo o nome do projeto, o nome dos alunos responsáveis e a disciplina em causa, proporcionando uma visão inicial e informativa sobre o contexto do trabalho.

As abas subsequentes concentram-se nas redes neuronais, sendo a primeira delas dedicada às redes "Shallow". Nesta aba, os utilizadores têm a capacidade de personalizar diversos aspetos, evidenciando a versatilidade da rede neural. Algumas das opções de personalização incluem:

- **“Patient” (63502, 44202):** Seleção do paciente específico para o qual a rede está sendo ajustada, permitindo uma adaptação personalizada aos dados de diferentes indivíduos.
- **“Number of Features” (15, 10, 3):** Definição do número de características relevantes para a tarefa em questão
- **“Type of Neural Network” (LRN ou FFN):** Opção entre Layer Recurrent Network (LRN) ou Fast Forward Network (FFN), proporcionando diferentes abordagens arquiteturais.
- **“Optimization” (None, Parallel, GPU, GPU+Parallel):** Escolha do método de otimização que melhor se adequa ao ambiente de computação, permitindo uma performance eficiente.
- **“Training functions” (traingd, traingda, traingdm, trainlm, trainscg):** Seleção da função de treino adequada à tarefa de aprendizagem.

- **“Training Style” (Incremental learning, Batch training):** Escolha entre *Incremental learning* e *Batch training*
- **“Layers delay”:** Introdução de atrasos nas redes neuronais
- **“Number of hidden layers”:** Definição do número de camadas ocultas na rede, permitindo um ajuste refinado da complexidade do modelo.
- **“Activation Function(s)”:** Definição das funções de ativação para cada camada oculta
- **“Number of neurons”:** Seleção do número de neurónios para cada camada oculta

A aba seguinte é dedicada às redes CNN (Convolution Neural Networks). Nesta seção, os utilizadores têm a capacidade de especificar diversos parâmetros cruciais para a configuração da rede. A seguir estão os parâmetros que podem ser personalizados:

- **“Patient” (63502, 44202):** Seleção do paciente
- **“Number of Features” (15,10,3):** Escolha do número de features relevantes
- **“Solver” (adam, sgdm, rmsprop)::** Seleção do *solver* a ser utilizado durante o treinamento da rede.
- **“Epochs”:** Determinação do número de *epochs*.
- **“Number of Convolution layers”:** Especificação do número de camadas de convolução na rede.
- **“Number of filters in each layer”:** Definição do número de filtros em cada camada de convolução.
- **“Size of filters”:** Indicação do tamanho dos filtros utilizados nas operações de convolução.
- **“Convolutional Stride”:** Estabelecimento do passo (*stride*) para as operações de convolução.
- **Type of “Pooling” (max, avg):** Escolha do tipo de operação de *pooling* a ser aplicado (*max pooling*, *average pooling*).
- **“Size of Pooling layers”:** Indicação do tamanho das camadas de pooling.
- **“Pooling Stride”:** Definição do passo (*stride*) para as operações de *pooling*.

A aba final é dedicada às redes neuronais do tipo LSTM (Long Short-Term Memory). Nesta seção, o utilizador pode ajustar parâmetros essenciais para a personalização da rede, incluindo:

- **“Patient” (63502, 44202):** Seleção do paciente.
- **“Features” (15,10,3):** Escolha do número de features.
- **“Solver” (adam, sgdm, rmsprop):** Seleção do *solver* a ser utilizado durante o treinamento da rede.
- **“Hidden Units”:** Especificação do número de unidades (neurónios) nas camadas ocultas da rede LSTM.

Aprendizagem Computacional 2023/2024
Assignment 2 – Prediction and detection of epileptic seizures

- **“Epochs”**: Determinação do número de *epochs*.
- **“Layer”**: Selecionar o número de camadas.

Após selecionar a rede neuronal desejada e definir os parâmetros, é possível proceder ao treinamento e teste da rede para obter os resultados. As métricas de desempenho são apresentadas no lado direito da interface, na secção denominada por “Performance”. Nessa área, os utilizadores podem avaliar diversos resultados, incluindo:

- **Número de crises epiléticas detetadas**: Indica a percentagem de crises que foram detetadas pela rede, calcula a accuracy da rede.
- **Especificidade e Sensibilidade para a previsão (“Prediction”)**: Oferece métricas que indicam a capacidade da rede em prever corretamente a ocorrência de crises.
- **Especificidade e Sensibilidade para a deteção (“Detection”)**: Apresenta métricas que refletem a capacidade da rede em detetar corretamente a presença de crises.

Essas métricas são fundamentais para avaliar o desempenho da rede neuronal tanto na previsão quanto na deteção de crises epiléticas. A apresentação clara desses resultados na interface proporciona uma análise abrangente do quão eficaz a rede se mostrou em relação aos objetivos estabelecidos, contribuindo para uma interpretação aprofundada do seu desempenho clínico.

A interface criada possui ainda a capacidade de importar uma rede previamente treinada da pasta “Trained Networks”. Após selecionar a rede, esta irá ser testada e os resultados irão aparecer no campo “Performance”.

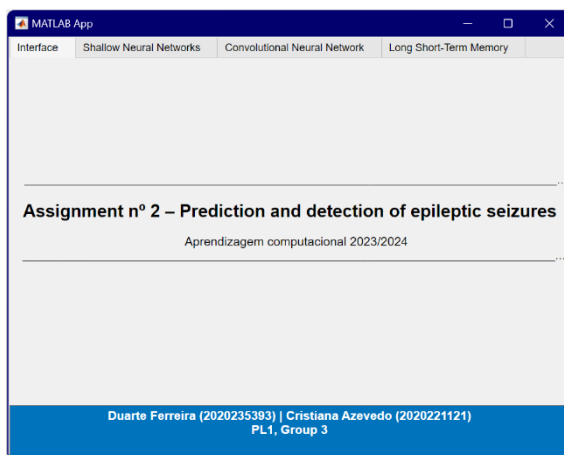


Figura 3. Interface do GUI

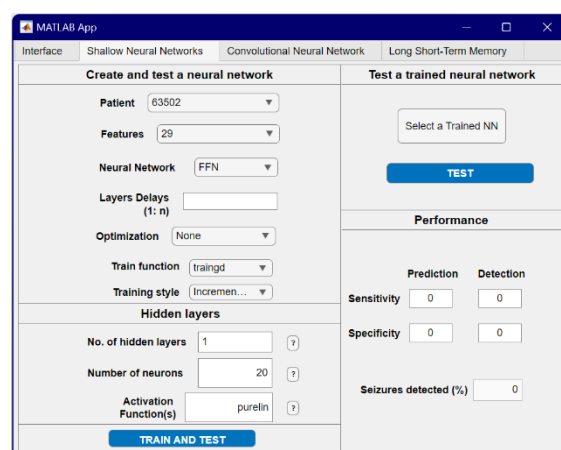


Figura 4. Shallow Neural Networks

Aprendizagem Computacional 2023/2024

Assignment 2 – Prediction and detection of epileptic seizures

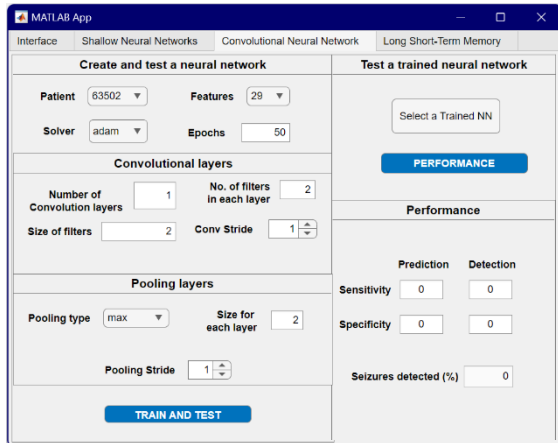


Figura 5. Convolutional Neural Networks

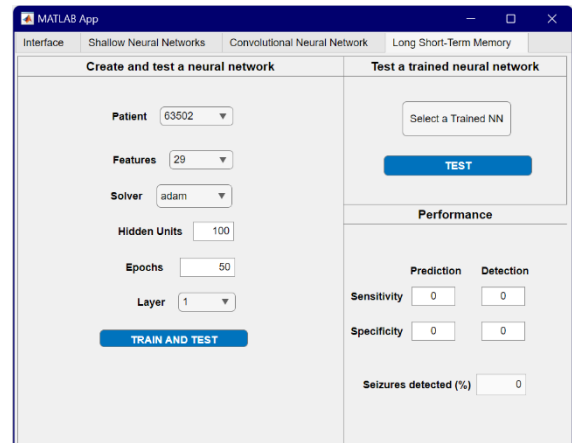


Figura 6. Long Short-Term Memory Neural Networks

7. Matlab Scripts

Tabela 2. Matlab scripts usados

Matlab Script	Descrição
<i>main_train.m</i>	Função principal para executar o treino de redes neuronais
<i>main_test.m</i>	Função principal para executar o teste de redes neuronais
<i>train_Shallow.m</i>	Função para o treino de <i>Shallow Neural Networks</i>
<i>train_LSTM.m</i>	Função para o treino de <i>Long Short-Term Memory Networks</i>
<i>train_CNN.m</i>	Função para o treino de <i>Convolutional Neural Networks</i>
<i>preProcessing.m</i>	Função para o pré-processamento dos dados extraídos dos EEGs
<i>LSTM_preProcessing.m</i>	Função para o pré-processamento adicional das redes neuronais <i>LSTM</i>
<i>CNN_preProcessing.m</i>	Função para o pré-processamento adicional das redes neuronais <i>CNN</i>
<i>PP_postProcessing.m</i>	Função para o método <i>Point by Point</i> do pós-processamento
<i>SS_postProcessing.m</i>	Função para o método <i>Seizure by Seizure</i> do pós-processamento
<i>autoenconders.m</i>	Função para reduzir o número de features em 29,15,10,3
<i>interface.mlapp</i>	Interface que permite a interação com o utilizador, oferecendo a possibilidade de treinar e testar os modelos de redes neuronais
<i>Clustering.m</i>	Função para representar graficamente os conjuntos de dados com apenas três <i>features</i>

8. Resultados

Para analisar os resultados, foram escolhidas as 7 melhores redes neuronais na previsão e na análise das crises epiléticas, para cada tipo de rede neuronal abordada neste trabalho (SNN, CNN e LSTM).

8.1- Redes SNN (Shallow Neural Network)

8.1.1- Paciente 63502

Tabela 3. Enumeração das 7 melhores *Shallow Neural Networks* na previsão de crises epiléticas

	<i>Features</i>	<i>Neural Network</i>	<i>Layer delay (l: n)</i>	<i>Optimization</i>	<i>Train Function</i>	<i>Training Style</i>	<i>No. hidden layers</i>	<i>No. neurons</i>	<i>Activation Functions</i>
<i>Network 1</i>	29	LRN	1	<i>None</i>	<i>traingda</i>	<i>Batch learning</i>	1	5	<i>purelin</i>
<i>Network 2</i>	29	LRN	5	<i>GPU</i>	<i>trainscg</i>	<i>Incremental learning</i>	2	3,2	<i>purelin,logsig</i>
<i>Network 3</i>	29	LRN	2	<i>Parallel</i>	<i>trainlm</i>	<i>Batch learning</i>	3	1,2,3	<i>purelin,logsig,tansig</i>
<i>Network 4</i>	15	LRN	20	<i>GPU</i>	<i>trainlm</i>	<i>Batch learning</i>	1	5	<i>purelin</i>
<i>Network 5</i>	15	LRN	10	<i>None</i>	<i>traingda</i>	<i>Incremental learning</i>	2	4,1	<i>purelin,purelin</i>
<i>Network 6</i>	10	LRN	2	<i>None</i>	<i>traingd</i>	<i>Incremental learning</i>	2	5,5	<i>purelin,tansig</i>
<i>Network 7</i>	15	FFN	1	<i>GPU</i>	<i>traingda</i>	<i>Incremental learning</i>	1	4	<i>tansig</i>

Tabela 4. Enumeração das 7 melhores *Shallow Neural Networks* na deteção de crises epiléticas

	<i>Features</i>	<i>Neural Network</i>	<i>Layer delay (l: n)</i>	<i>Optimization</i>	<i>Train Function</i>	<i>Training Style</i>	<i>No. hidden layers</i>	<i>No. neurons</i>	<i>Activation Functions</i>
<i>Network 8</i>	29	LRN	1	<i>None</i>	<i>trainscg</i>	<i>Batch learning</i>	1	1	<i>logsig</i>
<i>Network 9</i>	29	LRN	5	<i>GPU</i>	<i>trainscg</i>	<i>Batch learning</i>	2	1,2	<i>purelin,purelin</i>
<i>Network 10</i>	29	LRN	2	<i>GPU+Parallel</i>	<i>trainscg</i>	<i>Batch learning</i>	1	3	<i>logsig</i>
<i>Network 11</i>	29	LRN	3	<i>PGU+Parallel</i>	<i>traingda</i>	<i>Incremental learning</i>	2	2,2	<i>logsig,logsig</i>
<i>Network 12</i>	29	LRN	20	<i>Parallel</i>	<i>traingda</i>	<i>Incremental learning</i>	1	10	<i>tansig</i>
<i>Network 13</i>	10	FFN	2	<i>None</i>	<i>traingd</i>	<i>Incremental learning</i>	2	5,5	<i>purelin,tansig</i>
<i>Network 14</i>	15	FFN	2	<i>GPU+Parallel</i>	<i>traingd</i>	<i>Incremental learning</i>	2	3,2	<i>purelin,purelin</i>

Aprendizagem Computacional 2023/2024
Assignment 2 – Prediction and detection of epileptic seizures

Tabela 5. Resultados das 7 melhores *Shallow Neural Networks* na previsão de crises epiléticas

	<i>Network 1</i>	<i>Network 2</i>	<i>Network 3</i>	<i>Network 4</i>	<i>Network 5</i>	<i>Network 6</i>	<i>Network 7</i>
Sensibility - Prediction (%)	98.84	98.49	0	98.73	98.33	97.94	97.84
Specificity – Prediction (%)	10.5	11.69	99.99	12.06	13.32	13.92	13.93
Sensibility - Detection (%)	44.3	53.3	100	50.34	55.93	58.28	58.61
Specificity – Detection (%)	99.32	98.85	0	98.61	98.06	97.74	97.74
Seizures Detected (%)	64.4	53.8	100	51.68	55.93	58.05	58.45

Tabela 6. Resultados das 7 melhores *Shallow Neural Networks* na detecção de crises epiléticas

	<i>Network 8</i>	<i>Network 9</i>	<i>Network 10</i>	<i>Network 11</i>	<i>Network 12</i>	<i>Network 13</i>	<i>Network 14</i>
Sensibility - Prediction (%)	15.29	2.176	84.94	0	0	0	1.47
Specificity – Prediction (%)	90.46	98.42	27.77	99.57	100	100	97.93
Sensibility - Detection (%)	61.8	61.24	60.35	53.08	56.54	56.94	58.28
Specificity – Detection (%)	98.33	98.54	98.5	98.98	97.86	98.09	97.76
Seizures Detected (%)	65.05	63.09	62.08	53.58	56.32	57.21	59.84

Os resultados obtidos para as redes SNN no paciente 63502, revelaram-se melhores na detecção do que na predição, sendo o resultado esperado.

8.1.2- Paciente 44202

Tabela 7. Enumeração das 7 melhores *Shallow Neural Networks* na previsão de crises epiléticas

	<i>Features</i>	<i>Neural Network</i>	<i>Layer delay (1: n)</i>	<i>Optimization</i>	<i>Train Function</i>	<i>Training Style</i>	<i>No. hidden layers</i>	<i>No. neurons</i>	<i>Activation Functions</i>
<i>Network 1</i>	29	FFN	2	GPU	trainscg	Batch learning	2	1,2	purelin,purelin
<i>Network 2</i>	29	FFN	2	GPU+Parallel	trainscg	Batch learning	1	3	logsig
<i>Network 3</i>	29	FFN	3	Parallel	trainscg	Batch learning	1	2	purelin
<i>Network 4</i>	15	LRN	3	Parallel	traingda	Batch learning	1	2	logsig
<i>Network 5</i>	29	LRN	2	GPU	trainscg	Incremental learning	1	4	tansig
<i>Network 6</i>	29	LRN	1	GPU+Parallel	trainl,	Batch learning	1	5	purelin
<i>Network 7</i>	3	LRN	5	None	traingda	Incremental learning	1	2	logsig

Tabela 8. Enumeração das 7 melhores *Shallow Neural Networks* na deteção de crises epiléticas

	<i>Features</i>	<i>Neural Network</i>	<i>Layer delay (1: n)</i>	<i>Optimization</i>	<i>Train Function</i>	<i>Training Style</i>	<i>No. hidden layers</i>	<i>No. neurons</i>	<i>Activation Functions</i>
<i>Network 8</i>	29	FFN	3	GPU	traingda	Incremental learning	2	2,2	purelin,purelin
<i>Network 9</i>	15	FFN	2	GPU	traingda	Incremental learning	1	2	purelin
<i>Network 10</i>	15	FFN	1	gpu	trainscg	Batch learning	2	1,2	logsig,logsig
<i>Network 11</i>	15	LRN	2	Parallel	trainscg	Incremental learning	1	4	tansig
<i>Network 12</i>	3	LRN	1	GPU+Parallel	trainl,	Batch learning	1	5	purelin
<i>Network 13</i>	3	LRN	5	None	trailm	Batch learning	1	1	purelin
<i>Network 14</i>	3	FFN	2	GPU+Parallel	traingd	Incremental learning	1	4	tansig

Aprendizagem Computacional 2023/2024
Assignment 2 – Prediction and detection of epileptic seizures

Tabela 9. Resultados das 7 melhores *Shallow Neural Networks* na previsão de crises epiléticas

	<i>Network 1</i>	<i>Network 2</i>	<i>Network 3</i>	<i>Network 4</i>	<i>Network 5</i>	<i>Network 6</i>	<i>Network 7</i>
Sensibility - Prediction (%)	97.47	98.85	97.84	99.57	99.82	0.13	99
Specificity – Prediction (%)	18.63	14.65	13.93	14.65	13.54	94.24	17.04
Sensibility - Detection (%)	63.02	47.42	58.61	60.35	56.45	20.36	66.74
Specificity – Detection (%)	98.73	99.95	97.74	99.53	99.78	100	98.61
Seizures Detected (%)	66.26	48.49	58.45	59.49	55.41	20.14	65.81

Tabela 10. Resultados das 7 melhores *Shallow Neural Networks* na deteção de crises epiléticas

	<i>Network 8</i>	<i>Network 9</i>	<i>Network 10</i>	<i>Network 11</i>	<i>Network 12</i>	<i>Network 13</i>	<i>Network 14</i>
Sensibility - Prediction (%)	0	0	0	99,57	0	0	0
Specificity – Prediction (%)	100	100	100	14.65	100	100	100
Sensibility - Detection (%)	59,61	53,92	9,18	60,35	53,25	82,5	62,99
Specificity – Detection (%)	99,58	99,93	99,99	99,53	99,94	37,35	99,21
Seizures Detected (%)	58,86	53,29	6,689	59,43	52,51	81,98	62,32

Tal como no paciente 63502, a análise das redes SNN para o paciente 44202 revelou melhores resultados na deteção do que na predição, tendo existido casos em que se obteve sensibilidade de 0% na previsão de crises epiléticas.

8.2- Redes CNN (Convolutional Neural Networks)

8.2.1- Paciente 63502

Tabela 11. Enumeração das 7 melhores *Convolutional Neural Networks* na previsão de crises

	<i>Features</i>	<i>Solver</i>	<i>Epochs</i>	<i>No. Conv layers</i>	<i>No. Filters</i>	<i>Size filters</i>	<i>Conv Stride</i>	<i>Pooling type</i>	<i>Size layer</i>	<i>Pooling stride</i>
<i>Network 1</i>	15	<i>adam</i>	50	1	1	1	1	<i>max</i>	1	1
<i>Network 2</i>	29	<i>sgdm</i>	300	1	2	2	2	<i>max</i>	2	2
<i>Network 3</i>	29	<i>rmsprop</i>	340	2	2,3	1,2	2	<i>avg</i>	1,2	3
<i>Network 4</i>	29	<i>adam</i>	100	1	2	2	1	<i>avg</i>	3	1
<i>Network 5</i>	29	<i>rmsprop</i>	50	2	1,2	2,1	1	<i>max</i>	3,1	2
<i>Network 6</i>	3	<i>sgdm</i>	200	1	2	2	3	<i>avg</i>	1	2
<i>Network 7</i>	15	<i>rmsprop</i>	420	2	1,2	2,2	1	<i>max</i>	2,2	1

Tabela 12. Enumeração das 7 melhores *Convolutional Neural Networks* na detecção de crises

	<i>Features</i>	<i>Solver</i>	<i>Epochs</i>	<i>No. Conv layers</i>	<i>No. Filters</i>	<i>Size filters</i>	<i>Conv Stride</i>	<i>Pooling type</i>	<i>Size layer</i>	<i>Pooling stride</i>
<i>Network 8</i>	15	<i>sgdm</i>	100	1	2	1	1	<i>max</i>	1	1
<i>Network 9</i>	15	<i>rmsprop</i>	200	1	5	3	1	<i>avg</i>	2	15
<i>Network 10</i>	29	<i>adam</i>	200	1	1	1	1	<i>max</i>	1	1
<i>Network 11</i>	29	<i>adam</i>	50	2	1,2	2,1	1	<i>max</i>	3,1	2
<i>Network 12</i>	3	<i>sgdm</i>	180	3	1,1,1	1,1,2	1	<i>max</i>	1,1,1	1
<i>Network 13</i>	10	<i>sgdm</i>	100	1	2	2	1	<i>max</i>	3	1
<i>Network 14</i>	29	<i>sgdm</i>	340	2	1,2	1,2	2	<i>max</i>	1,2	2

Aprendizagem Computacional 2023/2024
Assignment 2 – Prediction and detection of epileptic seizures

Tabela 13. Resultados das 7 melhores *Convolutional Neural Networks* na previsão de crises

	<i>Network 1</i>	<i>Network 2</i>	<i>Network 3</i>	<i>Network 4</i>	<i>Network 5</i>	<i>Network 6</i>	<i>Network 7</i>
Sensibility - Prediction (%)	31.15	70.49	29.51	68.85	68.85	68.85	55.74
Specificity – Prediction (%)	100	99.76	100	100	98.3	98.05	99.51
Sensibility - Detection (%)	100	100	100	100	100	100	100
Specificity – Detection (%)	9.32	22.03	7.63	33.05	25.85	27.12	77.12
Seizures Detected (%)	100	100	100	100	100	100	100

Tabela 14. Resultados das 7 melhores *Convolutional Neural Networks* na detecção de crises

	<i>Network 8</i>	<i>Network 9</i>	<i>Network 10</i>	<i>Network 11</i>	<i>Network 12</i>	<i>Network 13</i>	<i>Network 14</i>
Sensibility - Prediction (%)	62.3	32.79	16.39	55.74	54.1	42.62	68.85
Specificity – Prediction (%)	100	100	100	99.03	99.27	99.76	98.3
Sensibility - Detection (%)	100	100	100	100	100	100	100
Specificity – Detection (%)	99.15	96.61	22.88	25.85	99.58	89.83	27.54
Seizures Detected (%)	100	100	100	100	100	100	100

Analisando os valores obtidos para as redes CNN do paciente 63502, na fase de previsão verifica-se uma elevada especificidade, logo podemos concluir que as redes treinadas identificam corretamente a ausência de convulsões. Por outro lado, na fase de detecção, existe uma elevada sensibilidade, o que significa que as redes treinadas identificam melhor a presença de convulsões.

8.2.2- Paciente 44202

Tabela 15. Enumeração das 7 melhores *Convolutional Neural Networks* na previsão de crises

	<i>Features</i>	<i>Solver</i>	<i>Epochs</i>	<i>No. Conv layers</i>	<i>No. Filters</i>	<i>Size filters</i>	<i>Conv Stride</i>	<i>Pooling type</i>	<i>Size layer</i>	<i>Pooling stride</i>
<i>Network 1</i>	29	<i>sgdm</i>	350	1	1	1	1	<i>max</i>	1	1
<i>Network 2</i>	29	<i>adam</i>	300	2	2,2	2,2	1	<i>avg</i>	2,2	1
<i>Network 3</i>	10	<i>rmsprop</i>	170	3	1,2,1	3,1,1	1	<i>avg</i>	2,1,1	1
<i>Network 4</i>	15	<i>adam</i>	50	2	2,2	2,1	1	<i>max</i>	1,2	1
<i>Network 5</i>	3	<i>rmsprop</i>	200	1	2	2	1	<i>avg</i>	1	1
<i>Network 6</i>	3	<i>adam</i>	250	2	2,1	1,1	1	<i>avg</i>	2,2	1
<i>Network 7</i>	10	<i>sgdm</i>	140	1	3	2	2	<i>max</i>	2	2

Tabela 16. Enumeração das 7 melhores *Convolutional Neural Networks* na detecção de crises

	<i>Features</i>	<i>Solver</i>	<i>Epochs</i>	<i>No. Conv layers</i>	<i>No. Filters</i>	<i>Size filters</i>	<i>Conv Stride</i>	<i>Pooling type</i>	<i>Size layer</i>	<i>Pooling stride</i>
<i>Network 8</i>	29	<i>rmsprop</i>	350	1	1	1	1	<i>max</i>	1	1
<i>Network 9</i>	29	<i>sgdm</i>	170	3	1,1,2	2,2,2	1	<i>max</i>	1,1,1	1
<i>Network 10</i>	10	<i>adam</i>	200	2	2,2	2,3	2	<i>max</i>	1,1	1
<i>Network 11</i>	3	<i>adam</i>	200	1	1	1	1	<i>max</i>	1	1
<i>Network 12</i>	3	<i>sgdm</i>	155	3	1,1,1	1,1,1	1	<i>max</i>	1,1,1	1
<i>Network 13</i>	29	<i>rmsprop</i>	220	1	2	2	1	<i>avg</i>	1	1
<i>Network 14</i>	10	<i>sgdm</i>	50	1	1	1	1	<i>max</i>	1	1

Aprendizagem Computacional 2023/2024
Assignment 2 – Prediction and detection of epileptic seizures

Tabela 17. Resultados das 7 melhores *Convolutional Neural Networks* na previsão de crises

	<i>Network 1</i>	<i>Network 2</i>	<i>Network 3</i>	<i>Network 4</i>	<i>Network 5</i>	<i>Network 6</i>	<i>Network 7</i>
Sensibility - Prediction (%)	70.49	78.69	82.61	72.83	64.13	48.91	66.3
Specificity – Prediction (%)	100	93.67	98.21	99.8	99.8	97.02	100
Sensibility - Detection (%)	100	100	100	100	100	100	100
Specificity – Detection (%)	98.73	41.1	32.89	35.57	22.82	34.56	23.15
Seizures Detected (%)	100	100	100	100	100	100	100

Tabela 18. Resultados das 7 melhores *Convolutional Neural Networks* na detecção de crises

	<i>Network 8</i>	<i>Network 9</i>	<i>Network 10</i>	<i>Network 11</i>	<i>Network 12</i>	<i>Network 13</i>	<i>Network 14</i>
Sensibility - Prediction (%)	86.89	81.97	10.87	57.61	60.87	70.65	54.1
Specificity – Prediction (%)	93.19	100	99.4	100	100	100	100
Sensibility - Detection (%)	100	100	100	100	100	100	100
Specificity – Detection (%)	69.07	99.58	64.11	20.13	96.64	83.89	99.15
Seizures Detected (%)	100	100	100	100	100	100	100

No paciente 44202, comparando com o paciente 63502, os resultados de sensibilidade e especificidade em ambas as fases foram melhores e, no caso da fase de predição, os valores foram mais próximos, o que evidencia o bom desempenho do modelo na previsão e na de crises epiléticas.

Em ambos os pacientes e na grande parte das redes treinadas, a detecção contempla resultados melhores face à previsão, o que é correto visto que o método deve ser capaz de detetar e analisar melhor os resultados do que os prever.

8.3- Redes LSTM (Long Short-Term Neural Networks)

8.3.1- Paciente 63502

Tabela 19. Enumeração das 7 melhores *Long Short-Term Neural Networks* na previsão de crises

	<i>Features</i>	<i>Solver</i>	<i>Hidden Units</i>	<i>Epochs</i>	<i>Layer</i>
<i>Network 1</i>	29	<i>adam</i>	200	100	2
<i>Network 2</i>	29	<i>adam</i>	1000	100	1
<i>Network 3</i>	29	<i>adam</i>	1000	100	2
<i>Network 4</i>	29	<i>rmsprop</i>	4000	100	2
<i>Network 5</i>	29	<i>sgdm</i>	1000	10	2
<i>Network 6</i>	29	<i>rmsprop</i>	1000	30	2
<i>Network 7</i>	29	<i>rmsprop</i>	450	15	1

Tabela 20. Enumeração das 7 melhores *Long Short-Term Neural Networks* na detecção de crises

	<i>Features</i>	<i>Solver</i>	<i>Hidden Units</i>	<i>Epochs</i>	<i>Layer</i>
<i>Network 8</i>	29	<i>adam</i>	20	10	1
<i>Network 9</i>	29	<i>adam</i>	10	20	2
<i>Network 10</i>	29	<i>sgdm</i>	100	50	2
<i>Network 11</i>	29	<i>sgdm</i>	1000	50	2
<i>Network 12</i>	29	<i>rmsprop</i>	100	30	1
<i>Network 13</i>	29	<i>rmsprop</i>	450	50	2
<i>Network 14</i>	29	<i>adm</i>	360	20	2

Aprendizagem Computacional 2023/2024
Assignment 2 – Prediction and detection of epileptic seizures

Tabela 21. Resultados das 7 melhores *Long Short-Term Neural Networks* na previsão de crises

	<i>Network 1</i>	<i>Network 2</i>	<i>Network 3</i>	<i>Network 4</i>	<i>Network 5</i>	<i>Network 6</i>	<i>Network 7</i>
Sensibility - Prediction (%)	2.47	2.412	2.039	14.69	98.25	7.69	5.49
Specificity – Prediction (%)	98.72	98.67	98.94	92.4	13.27	96.5	97.22
Sensibility - Detection (%)	64.04	62.64	62.81	60.12	54.53	63.2	63.81
Specificity – Detection (%)	97.84	98.52	98.47	98.56	98.92	98.92	98.02
Seizures Detected (%)	65.49	64.26	64.26	62.08	54.92	65.1	64.88

Tabela 22. Resultados das 7 melhores *Long Short-Term Neural Networks* na deteção de crises

	<i>Network 8</i>	<i>Network 9</i>	<i>Network 10</i>	<i>Network 11</i>	<i>Network 12</i>	<i>Network 13</i>	<i>Network 14</i>
Sensibility - Prediction (%)	1.06	0.82	0.08	0.88	1.12	3.31	2.06
Specificity – Prediction (%)	99.94	99.38	99.77	98.88	99.31	98.03	98.88
Sensibility - Detection (%)	66.33	65.44	59.68	56.94	65.27	63.96	63.37
Specificity – Detection (%)	96.53	96.59	98.39	98.8	96.99	97.95	98.16
Seizures Detected (%)	67.28	66.22	59.68	58.5	66.44	65.38	64.93

Neste caso do paciente 63502 para as redes LSTM, em ambas as fases de previsão e deteção verifica-se uma elevada especificidade comparativamente com a sensibilidade, o que nos leva a referir que as redes treinadas identificam melhor a ausência de convulsões, do que a presença de convulsões.

8.3.2- Paciente 44202

Tabela 23. Enumeração das 7 melhores *Long Short-Term Neural Networks* na previsão de crises

	<i>Features</i>	<i>Solver</i>	<i>Hidden Units</i>	<i>Epochs</i>	<i>Layer</i>
<i>Network 1</i>	29	<i>adam</i>	1000	10	1
<i>Network 2</i>	29	<i>sgdm</i>	1000	10	1
<i>Network 3</i>	15	<i>rmsprop</i>	1000	10	2
<i>Network 4</i>	29	<i>rmsprop</i>	1000	20	1
<i>Network 5</i>	10	<i>sgdm</i>	100	10	1
<i>Network 6</i>	3	<i>adam</i>	1000	10	2
<i>Network 7</i>	3	<i>rmsprop</i>	600	15	2

Tabela 24. Enumeração das 7 melhores *Long Short-Term Neural Networks* na detecção de crises

	<i>Features</i>	<i>Solver</i>	<i>Hidden Units</i>	<i>Epochs</i>	<i>Layer</i>
<i>Network 8</i>	29	<i>sgdm</i>	500	30	1
<i>Network 9</i>	29	<i>rmsprop</i>	500	50	1
<i>Network 10</i>	29	<i>rmsprop</i>	1000	40	2
<i>Network 11</i>	29	<i>adam</i>	300	20	1
<i>Network 12</i>	29	<i>adam</i>	1000	50	2
<i>Network 13</i>	29	<i>rmsprop</i>	350	50	1
<i>Network 14</i>	29	<i>adam</i>	1500	20	1

Aprendizagem Computacional 2023/2024
Assignment 2 – Prediction and detection of epileptic seizures

Tabela 25. Resultados das 7 melhores *Long Short-Term Neural Networks* na previsão de crises

	<i>Network 1</i>	<i>Network 2</i>	<i>Network 3</i>	<i>Network 4</i>	<i>Network 5</i>	<i>Network 6</i>	<i>Network 7</i>
Sensibility - Prediction (%)	6.217	99.23	99.7	8.617	100	98.17	100
Specificity – Prediction (%)	95.11	16.82	13.88	95.13	6.739	18.29	11.5
Sensibility - Detection (%)	75.59	67.63	57.64	74.28	28.5	50.32	48.64
Specificity – Detection (%)	99.59	99.18	99.68	99.01	100	99.97	100
Seizures Detected (%)	76.51	66.82	57	75.73	28.39	50.17	48.2

Tabela 26. Resultados das 7 melhores *Long Short-Term Neural Networks* na detecção de crises

	<i>Network 8</i>	<i>Network 9</i>	<i>Network 10</i>	<i>Network 11</i>	<i>Network 12</i>	<i>Network 13</i>	<i>Network 14</i>
Sensibility - Prediction (%)	0	3	6.4	1.583	1.117	2.117	1.667
Specificity – Prediction (%)	100	97.42	95.59	98.77	98.94	98.33	98.91
Sensibility - Detection (%)	68.23	72.58	76.69	75.25	75.47	72.02	75.59
Specificity – Detection (%)	99.05	99.28	98.97	99.12	99.12	99.2	99.09
Seizures Detected (%)	67.52	73.43	75.03	75.77	76.2	72.54	76.14

Tal como no paciente 63502, no paciente 44202, as redes neuronais tiveram valores de especificidade maiores que os de sensibilidade e, no geral, as redes com o número de features igual a 15, 10 e 3 apresentaram os piores resultados.

Analisando a arquitetura de redes LSTM, percebemos que, em ambos pacientes e em especial na previsão, os valores mais altos de especificidade foram obtidos aquando da obtenção dos valores mais baixos na sensibilidade, e vice-versa. Isto significa, que este modelo não é ótimo.

9. Conclusão

De forma global, podemos dizer que o objetivo do trabalho foi parcialmente alcançado, verificando que as redes treinadas são melhores a detetar crises do que a prevê-las. Este facto pode estar relacionado com uma dificuldade intrínseca da tarefa de previsão em relação à deteção. Na previsão há mais incerteza, baseando-se nos pontos pré-ictais, enquanto na deteção são apenas os pontos ictais que são diretamente analisados.

Os resultados obtidos para o doente 44202 foram superiores aos do doente 63502, que, no entanto, à exceção do caso da CNN, continuam a ser maus também na deteção. Uma explicação possível é o facto de o EEG do doente 44202 conter mais informações do que o do doente 63502. Mais concretamente, há mais crises para analisar (22 vs 19) e uma duração média mais longa das mesmas (131,6 vs 102,8 segundos).

Analisando cada rede individualmente, a pior arquitetura demonstrou ser a LSTM. De facto, também no melhor caso (deteção no doente 44202), os desempenhos em alguns casos foram péssimos tendo em vista a obtenção de 0% e 3% em SE na fase de deteção. O facto de existir um contrabalanço entre os valores de SE e SP em ambas as fases de deteção e previsão, leva a concluir que este modelo de redes neuronais não é ótimo para a deteção e previsão de crises epiléticas.

Em relação às redes das SNN, como seria de esperar, em ambos os pacientes estas apresentaram melhores resultados aquando do uso de DNN. Dentro das SNN, as FFN apresentaram resultados ligeiramente melhores do que as LRN. Nos dois tipos de SNN foram obtidos valores de especificidade na deteção elevados, o que significa que estas redes neuronais foram capazes de classificar corretamente a ausência de pontos ictal. Não foi detetada qualquer influência particular dos parâmetros com o desempenho do classificador.

Por fim, a CNN pode afirmar-se sem margem como o modelo de rede neuronal como a melhor arquitetura. Verifica-se que os resultados para a deteção são os melhores possíveis (100% em SP e em SE) para ambos os pacientes, enquanto para todas as outras redes os resultados foram inferiores para o paciente 44202 e piores para o paciente 63502. No entanto, um aspeto importante a salientar é que, pelo método de pós-processamento *Seizure by Seizure* foram obtidas percentagens de 100% na deteção das crises epiléticas em todos os casos. Isto significa que possivelmente, foi detetado um número de *seizures* maior do que aquele que realmente se registou (existiram falsos positivos). Em relação aos parâmetros, embora tenhamos realizado algumas combinações e tido em conta várias opções, não foi encontrada qualquer dependência entre o desempenho e os parâmetros.

É necessário ter em conta que o problema abordado, a epilepsia, é de uma complexidade bastante elevada, contando já com dezenas de anos de estudos, e sem uma resposta concreta. Tendo isto em conta e juntando o facto de ser difícil obter um dataset em que o início e o fim dos períodos ictal e pré-ictal estejam bem definidos, consideramos que os resultados neste trabalho não foram satisfatórios devido ao facto das redes LSTM terem apresentado resultados pouco animadores e as SNN também não serem excelentes.

De forma a obter melhores resultados, seria necessário a experimentação de mais combinações dos parâmetros, principalmente no que às redes DNN. Muito possivelmente, desse modo, estas já iriam ser obtidos resultados bem mais destacados das SNN, inclusive porque, algumas das redes LSTM se revelaram melhores a prever crises do que a as detetar, resultados que deveriam ser analisados de forma mais profunda. No entanto, dado o tempo e recursos computacionais disponíveis, tal não foi possível estudar.

Em conclusão, a CNN revelou-se a arquitetura mais promissora para a resolução deste problema. O treino foi efetuado apenas em dois doentes e os resultados podem depender fortemente do caso específico. Assim, os desenvolvimentos futuros deste estudo devem consistir no treino de um maior número de doentes, de modo a obter uma maior quantidade de dados capazes de descrever melhor a variabilidade inter-individual. Desta forma, poderia ser possível construir um algoritmo mais geral, capaz de se especializar para um único doente e para uma tarefa específica.

10. Bibliografia

- [1]. Dourado, A. 2020. Assignment 2 - Prediction and detection of epileptic seizures - Guião do presente trabalho.
- [2]. Dourado, A., 2020. Chapter 5 - Dynamic Networks and Deep Learning - Slides das aulas de Aprendizagem Computacional.
- [3]. Dourado, A., 2020. Chapter 3 - Clustering - Slides das aulas de Computação Neuronal e Sistemas Difusos.
- [4] Introduction To Autoencoders - A Brief Overview. Abhijit Roy, 2020. Disponível em: <https://towardsdatascience.com/introduction-to-autoencoders-7a47cf4ef14b>